# 实验三: MyJoin\_Hive

组号:2020st32

小组成员:

171860607 白晋斌

171860033 黄诗涵

171180541 祖东珏

联系方式:810594956@qq.com

分工:因本次实验较为简单,小组成员决定分别独立完成代码编写,实验报告中分别讲述了三位同学的代码思路. 此外,三位同学的源代码、JAR 包、JAR 包执行方式说明详见附件.

# 目录

实验任务	3
实验过程	3
1. Map 和 Reduce 的设计思路	3
1.2 祖东珏	3
1.2 祖东环	4
1.3 白晋斌	6
2. 集群测试	
2.1 运行 Jar 包,输出到/user/2020st32/output_3_1	7
2.2 查看结果	7
3. Hive 管理输出结果	
3.1 建表	Ω
3.2 SELECT 语句查询内容	٥
5.2 SELECT 语可重调内合	
WebUI 执行报告	9
实验感悟	10
参考资料	10

## 实验任务

- 1. 使用 MapReduce 完成/data/exercise\_3 目录下两张表 order.txt 和 product.txt 的 join 操作。
- 2. 使用 Hive 管理输出结果
- 3. 能查询到建的表并用 select 语句查询内容

## 实验过程

1. Map 和 Reduce 的设计思路

此部分分别展示三位同学的代码设计思路与伪代码.

#### 1.1 黄诗涵

order.txt 是订单信息,包括"订单 ID"(oid)、"订单日期"(odate)、"商品 ID" (pid)、"购买数量"(oamount)

product.txt 是商品信息,包括"商品 ID"(pid)、"商品名称"(pname), "商品单价"(price)

要对两张表进行 join 操作也就是将商品信息里的名称和单价填充到有对应 pid 的订单信息中,相当于做笛卡尔积。

定义一个 public class OrderBean implements WritableComparable<OrderBean> 类中包含 oid,odate,pid,pname,price,oamount 将它作为 mapper 的输出,reducer 的输入。

#### 1.1.1 自定义 compareTo 函数

```
    public int compareTo(OrderBean other)

2.
3.
           if(pid 不相等)
4.
               return pid.compareTo(other.pid);
5.
           else
6.
7.
               if(pname 为空)
8.
9.
                   if(other.pname 为空)
                       return compareOid(other);//两个都是订单信息,用 oid 排序
10.
11.
                   else return -pname.compareTo(other.pname);//将商品信息排在订单信息之
   前
12.
               }
13.
               else
14.
15.
                   if(other.pname 为空)
16.
                       return -pname.compareTo(other.pname);
17.
                   else return price.compareTo(other.price);//pid 相同的商品信息根据价格
   排序
18.
19.
           }
20.
```

#### 1.1.2 自定义排序

需要定义 public class JoinComparator extends WritableComparator 然后设置 job.setGroupingComparatorClass(JoinComparator.class); JoinComparator 重写 compare 方法,直接调用上面的 compareTo 即可

有了以上的数据结构的排序方法,mapper 函数要做的就是将读入的信息填入 OrderBean 并作为 key 传给 reducer,程序就会自动按照自定义的排序算法给 key 排序。

reducer 会按如下顺序接收到 mapper 的输出:

```
hadoop@ubuntu:~/hadoop_installs/hadoop-2.7.1$ hadoop fs -cat /output22/part-r-00000
                           chuizi 3999
huawei 3999
1003
         20190731
1004
         20190731
                                                      23
1007
         20190801
1009
         20190802
                                                      10
                                                      2
1010
         20190802
                                    2999
                           xiaomi
1002
         20190731
                                                      100
         20190801
1006
                                                      20
1011
         20190802
                                                      14
                                                      18
1012
         20190802
                           apple
                                    5999
1001
         20190731
         20190801
                                                      55
1005
1008
         20190801
                                                      23
```

显然 pid 相同的被划分为了一组,并且第一组就是商品信息.

#### 1.1.3 reducer

```
public static class JoinReducer extends Reducer<OrderBean,Text,Text,Text> {
2.
           OrderBean productInfo=new OrderBean(); //保存商品信息
3.
           @Override
4.
           protected void reduce(OrderBean key, Iterable<Text> values,Context context)
    throws IOException,InterruptedException {
               if(key.type().compareTo("product")==0) {//收到商品信息,更新
5.
                   productInfo.setPrice(key.getPrice());
6.
7.
                   productInfo.setPname(key.getPname());
8.
               }
9.
               else {
                                        //收到订单信息,将保存的商品信息填入
10.
                   key.setPname(productInfo.getPname());
11.
                   key.setPrice(productInfo.getPrice());
12.
                   for(Text value:values)
13.
                       context.write(new Text(key.toString()),new Text(""));
14.
15.
16.
17.
```

#### 填入商品信息后按如下格式打印:

```
hadoop fs -cat /output24/part-r-00000
1003
         20190731
                                    huawei
                                             3999
1004
         20190731
                                    huawei
                                             3999
                                                      23
1007
         20190801
                                    huawei
                                             3999
1009
         20190802
                           2
                                    huawei
                                             3999
                                                       10
1010
         20190802
                                             3999
                                    huawei
1002
         20190731
                                             2999
                                                       100
                                    xiaomi
1006
         20190801
                                    xiaomi
                                             2999
                                                      20
1011
                                                       14
         20190802
                                    xiaomi
                                             2999
1012
         20190802
                                    xiaomi
                                             2999
                                                      18
1001
         20190731
                                    apple
                                             5999
1005
         20190801
                                    apple
                                             5999
                                                      55
1008
        20190801
                                    apple
                                             5999
```

#### 1.2 祖东环

本次实验中需要实现 product 表和 order 表的 join 操作,product 表和 order 表的主键均为商品 ID(pid),因此基本思路是将 product 表和 order 表中 pid 相同的记录分配到同一个节点进行 reduce 操作,将 product 的商品名称(pname)和商品单价(price)填入订单中。

问题在于,如果直接使用 pid 作为 key,虽然能够正确将对应的记录分配到同一个 Reducer 中,但是无法知道哪一条记录是 product 表中的,需要遍历当前 Reducer 中的所有记录,时间复杂度高。因此,可以利用 MapReduce 过程中系统的排序来对相同 pid 的记录进行排序,将 product 表中的记录放在最前面,后面依次跟上 order 中的记录.

#### 1.2.1 数据类型

本实验中定义一个数据类型 Record

```
enum RecordType {
    Unknown, Product, Order
public class Record implements WritableComparable<Record> {
    public Long pid;
    public String pname;
    public Float price;
    public Long oid;
    public String odata;
    public Long oamount;
    RecordType type;
public Record() {...}
   public int compareTo(Record o) {...}
   public void write(DataOutput dataOutput) throws IOException {...}
    public void readFields(DataInput dataInput) throws IOException {...}
    public String toString() { return oid + " " + odata + " " + pid + " "
1
```

i.Record 类型中有一条记录的所有内容:商品 ID、商品名称、商品单价、订单 ID、订单日期、购买数量。添加了一条数据用以标示记录属于 Product 或 Order。

ii.为了实现排序后 product 表记录在最前, order 表记录按照订单 ID 排序的功能, 实现了 compareTo()函数:

```
public int compareTo(Record o) {
    int idcompare = this.pid.compareTo(o.pid);
    if(idcompare != 0)
        return idcompare;
    else {
        if(this.type == RecordType.Product && o.type == RecordType.Product)
            return this.pname.compareTo(o.pname);
        else if(this.type == RecordType.Order && o.type == RecordType.Order)
            return this.oid.compareTo(o.oid);
        else if(this.type == RecordType.Product && o.type == RecordType.Order)
            return 1;
        else
            return -1;
    }
}
```

iii.剩余函数用以满足 WritableComparable 接口要求和输出要求

#### 1.2.2 Map

本实验中的 Map 函数较为简单,仅需要根据数据来自 product 或 order 表进行填充并发射即可。

#### @Override

```
public void map(LongWritable key, Text value, Context context) throws IOException, InterruptedException {
   String[] attributes = value.toString().split( regex: " ");
   Record record = new Record();
   if(filename.equals("product.txt")) {...}
   else if(filename.equals("order.txt")) {...}
   else
        throw new IOException("Unknown Filename!" + filename.toString());
   context.write(record, NullWritable.get());
}
```

#### 1.2.3 Partition

由于使用自定义数据类型,可能导致 pid 相同的记录被分配到不同的 Reducer中,因此重新实现了以 id 作为分类依据的 Partitioner

```
// Partitioner
```

```
public static class MyJoinPartitioner extends HashPartitioner<Record, NullWritable> {
    @Override
    public int getPartition(Record key, NullWritable value, int numReduceTasks) {
        return key.pid.intValue() % numReduceTasks;
    }
}
```

#### 1.2.4 Reduce

在实现了上述功能后,Reducer 会依次接收到按 pid 排序的一系列记录,其中每个 pid 中第一个接收到的记录为 product,此时记录下 pname 和 price 用以后续填充。在接收到 order 记录后用之前记录的 pname 和 price 进行填充后即可输出。

```
@Override
public void reduce(Record key, Iterable<NullWritable> values, Context context) throws IOException, InterruptedException {
    if(key.type == RecordType.Product) {
        curPname = key.pname;
        curPrice = key.price;
    }
    else if(key.type == RecordType.Order) {
        key.pname = curPname;
        key.price = curPrice;
        context.write(key, NullWritable.get());
    }
    else
        throw new IOException("Record type Unknown!");
}
```

#### 1.3 白晋斌

#### 1.3.1 Map

要根据数据来自 product 或 order 表,分别切分并提取对应部分,将 pid 作为 key, 其他部分作为 value,并增加一个标示符记忆来自哪个表,我们将次标识符和 value 一并 作为 map 的输出 value。

```
protected void map(LongWritable key, Text value, Context context) throws IOException, InterruptedException {
   String fileName = ((FileSplit)context.getInputSplit()).getPath().getName().split(regex: "(.txt)|(.TXT)")[0];
   String line =value.toString();
   if (line == null || line.equals("")) return;
   String[] lines = line.split(DELIMITER);
   if(fileName.equals("order")){
      String id1=lines[0];
      String pid3=lines[2];
      String pid3=lines[2];
      String number6=lines[3];
      context.write(new Text(pid3), new Text( string: "order"+DELIMITER+id1+DELIMITER+order_date2+DELIMITER+pid3+DELIMITER+number6));
   }
   else if(fileName.equals("product")){
      String pid3=lines[0];
      String pid3=lines[0];
      String price5=lines[1];
      String price5=lines[2];
      context.write(new Text(pid3), new Text( string: "product"+DELIMITER+pid3+DELIMITER+name4+DELIMITER+price5));
}
```

#### 1.3.2 Reduce

因为同一 pid 被分到同一 reduce 函数,我们可以直接遍历 value,根据标识符存为两个 vector,按照左连接的定义,我们遍历 order 的 vector,对每个 order 遍历 product 的 vector 生成输出,如果找不到对应的 product 则设置对应部分为 NULL.

之后将连接出的新数据作为 key 输出即可.

#### 1.3.3 高级算法

可直接用 DataJoin 类实现 Map 端 Join 和 Reduce 端 Join.在此不做赘述,该方式可大大提高程序鲁棒性.

#### 2. 集群测试

2.1 运行 Jar 包,输出到/user/2020st32/output\_3\_1

请输入MR提交命令,例: hadoop jar /home/data/WordCount.jar WordCount /zj/input /zj/output

hadoop jar /home/2020st32/MyJoin.jar /data/exercise\_3 /user/2020st32/output\_3\_1

#### 2.2 查看结果

在大数据分布文件存储->HDFS 分布式存储中找到输出的文件



#### 3. Hive 管理输出结果

#### 3.1 建表

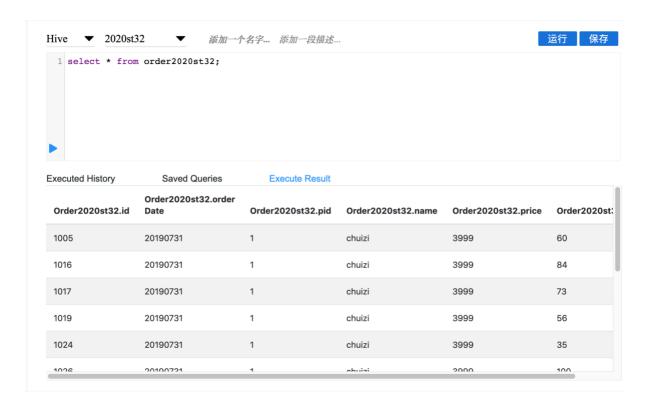
输入语句: create table order2020st32 (id string,order\_date string,pid string,name string,price string,num string) row format delimited fields terminated by ' 'location '/user/2020st32/output\_3\_1/';

创建表后能看到出现一个名字为 order2020st32 的 table.

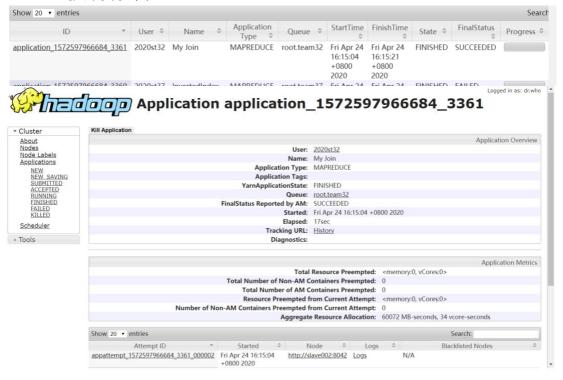
# Tab Name order2020st32

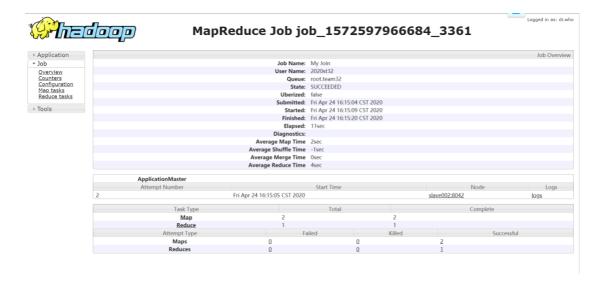
#### 3.2 SELECT 语句查询内容





# WebUI 执行报告





# 实验感悟

1. MapReduce wordcount 测试卡死在 running job,原因竟然是

```
20/04/26 23:56:07 INFO input.FileInputFormat: Total input paths to process: 2
20/04/26 23:56:07 INFO mapreduce.JobSubmitter: number of splits:2
20/04/26 23:56:07 INFO mapreduce.JobSubmitter: number of splits:2
20/04/26 23:56:08 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1587226935256_0013
20/04/26 23:56:08 INFO impl.YarnClientImpl: Submitted application application_1587226935256_0013
20/04/26 23:56:08 INFO mapreduce.Job: The url to track the job: http://192.168.1.104:8088/proxy/application_1587226935256_0013/
20/04/26 23:56:08 INFO mapreduce.Job: Running job: job_1587226935256_0013
```

之前执行 MapReduce 的时候强制按 CTRL+C 退出了,tmp 里面保存了 job 的一些信息,而 safemode 是无法删除 tmp 里面的这些信息的解决方案:重新格式化.

参考资料[2][3]

2.生成的 jar 包一度很大怎么办?参考[4][5]

# 参考资料

- [1] https://stackoverflow.com/questions/40315820/error63-40-java-incompatible-types-org-apache-hadoop-mapreduce-job-cannot
- [2] https://www.cnblogs.com/TTyb/p/8274246.html
- [3] https://blog.csdn.net/hukun910903/article/details/79736257
- [4] https://jingyan.baidu.com/article/48b558e3f8f6637f39c09a44.html
- [5] https://blog.csdn.net/ming19951224/article/details/81416387